Impor Data dan Konsep Tidy Data

Muhammad Aswan Syahputra 4/9/2019

Contents

Impor Data	 	 	 	 									 						
Tidy data .																			!

Impor Data

Anda dapat menggunakan paket readr untuk mengimpor berkas lokal di komputer atau dari pranala (URL). Anda dapat mengaktifkan paket readr dengan cara menjalankan library(nama_paket) seperti contoh berikut: (Petunjuk: Tekan Ctrl + Enter untuk menjalankan baris kode.)

```
library(readr)
```

```
## Warning: package 'readr' was built under R version 3.5.3
```

Paket hanya perlu dipasang satu kali melalui fungsi install.packages("nama_paket") dan harus selalu diaktifkan setiap menggawali kerja menggunakan R agar fungsi-fungsi yang tersedia dalam paket tersebut dapat digunakan. Sebagai contoh, kita akan menggunakan fungsi read_csv() dari paket readr untuk mengimpor data 'evals.csv' dari folder 'data-raw' sebagai berikut:

```
evals <- read_csv("../data-raw/evals.csv")</pre>
```

```
## Parsed with column specification:
## cols(
##
     .default = col_double(),
##
     rank = col_character(),
     ethnicity = col_character(),
##
##
     gender = col_character(),
     language = col_character(),
##
     cls level = col character(),
##
     cls_profs = col_character(),
##
##
     cls_credits = col_character(),
##
     pic_outfit = col_character(),
##
    pic_color = col_character()
## )
```

See spec(...) for full column specifications.

```
evals
```

```
##
        4.7 tenu~ minority female english
                                                36
                                                             55.8
                                                                            24
##
                                                36
                                                             68.8
    2
        4.1 tenu~ minority female english
                                                                            86
                                                             60.8
##
        3.9 tenu~ minority female english
                                                36
                                                                            76
##
        4.8 tenu~ minority female english
                                                36
                                                             62.6
                                                                            77
##
    5
        4.6 tenu~ not mino~ male
                                    english
                                                59
                                                             85
                                                                            17
##
                                                59
                                                                            35
   6
        4.3 tenu~ not mino~ male
                                    english
                                                             87.5
##
   7
        2.8 tenu~ not mino~ male
                                    english
                                                59
                                                             88.6
                                                                            39
##
   8
        4.1 tenu~ not mino~ male
                                    english
                                                51
                                                            100
                                                                            55
##
   9
        3.4 tenu~ not mino~ male
                                    english
                                                51
                                                             56.9
                                                                           111
## 10
        4.5 tenu~ not mino~ female english
                                                40
                                                             87.0
                                                                            40
## # ... with 453 more rows, and 13 more variables: cls_students <dbl>,
       cls_level <chr>, cls_profs <chr>, cls_credits <chr>,
## #
## #
       bty_f1lower <dbl>, bty_f1upper <dbl>, bty_f2upper <dbl>,
       bty_m1lower <dbl>, bty_m1upper <dbl>, bty_m2upper <dbl>,
## #
## #
       bty_avg <dbl>, pic_outfit <chr>, pic_color <chr>
```

Anda dapat menggunakan fungsi glimpse dari paket dplyr untuk melihat ringkasan data. tersebut. Isilah '____' dengan jawaban yang tepat untuk melihat ringkasan data evals! Ada berapa variable dan observasi pada data evals tersebut?

```
library(dplyr)
```

```
## Warning: package 'dplyr' was built under R version 3.5.3

##
## Attaching package: 'dplyr'

## The following objects are masked from 'package:stats':
##
## filter, lag

## The following objects are masked from 'package:base':
##
## intersect, setdiff, setequal, union
```

glimpse(evals)

```
## Observations: 463
## Variables: 21
## $ score
                   <dbl> 4.7, 4.1, 3.9, 4.8, 4.6, 4.3, 2.8, 4.1, 3.4, 4.5...
## $ rank
                   <chr> "tenure track", "tenure track", "tenure track", ...
                   <chr> "minority", "minority", "minority", "minority", ...
## $ ethnicity
                   <chr> "female", "female", "female", "female", "male", ...
## $ gender
## $ language
                   <chr> "english", "english", "english", "english", "eng...
## $ age
                   <dbl> 36, 36, 36, 36, 59, 59, 59, 51, 51, 40, 40, 40, ...
## $ cls_perc_eval <dbl> 55.81395, 68.80000, 60.80000, 62.60163, 85.00000...
                  <dbl> 24, 86, 76, 77, 17, 35, 39, 55, 111, 40, 24, 24,...
## $ cls_did_eval
                  <dbl> 43, 125, 125, 123, 20, 40, 44, 55, 195, 46, 27, ...
## $ cls_students
## $ cls_level
                   <chr> "upper", "upper", "upper", "upper", "upper", "up...
                   <chr> "single", "single", "single", "single", "multipl...
## $ cls_profs
                   <chr> "multi credit", "multi credit", "multi credit", ...
## $ cls_credits
```

```
## $ btv f1lower
                   <dbl> 5, 5, 5, 5, 4, 4, 4, 5, 5, 2, 2, 2, 2, 2, 2, 2, ...
## $ bty_f1upper
                   <dbl> 7, 7, 7, 7, 4, 4, 4, 2, 2, 5, 5, 5, 5, 5, 5, 5, ...
## $ bty f2upper
                   <dbl> 6, 6, 6, 6, 2, 2, 2, 5, 5, 4, 4, 4, 4, 4, 4, 4, ...
## $ bty_m1lower
                   <dbl> 2, 2, 2, 2, 2, 2, 2, 2, 3, 3, 3, 3, 3, 3, 3, ...
                   <dbl> 4, 4, 4, 4, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, ...
## $ bty m1upper
## $ bty m2upper
                   <dbl> 6, 6, 6, 6, 3, 3, 3, 3, 2, 2, 2, 2, 2, 2, 2, ...
                   <dbl> 5.000, 5.000, 5.000, 5.000, 3.000, 3.000, 3.000,...
## $ bty avg
                   <chr> "not formal", "not formal", "not formal", "not f...
## $ pic_outfit
## $ pic_color
                   <chr> "color", "color", "color", "color", "color", "co...
```

Selain itu Anda juga dapat menggunakan fungsi skim() dari paket skimr untuk melihat rangkuman data. Pada *chunck* berikut, tuliskan kode untuk mengaktifkan paket skimr dan menjalankan fungsi skim pada data evals! Perbedaaan apakah yang Anda temukan antara penggunaan fungsi glimpse() dan skim()?

```
library(skimr)
## Warning: package 'skimr' was built under R version 3.5.3
##
## Attaching package: 'skimr'
## The following object is masked from 'package:stats':
##
##
       filter
skim(evals)
## Skim summary statistics
##
    n obs: 463
    n variables: 21
##
##
##
   -- Variable type:character ----
##
       variable missing complete
                                    n min max empty n_unique
##
    cls credits
                      0
                              463 463
                                       10
                                           12
                                                   0
                                                             2
                      0
                                             5
                                                             2
##
      cls_level
                              463 463
                                         5
                                                   0
                                                             2
##
      cls_profs
                      0
                              463 463
                                         6
                                             8
                                                   0
```

```
0
                                               12
                                                                 2
##
      ethnicity
                                463 463
                                            8
                                                       0
##
          gender
                        0
                                463 463
                                            4
                                                6
                                                       0
                                                                 2
##
       language
                        0
                                463 463
                                            7
                                               11
                                                       0
                                                                 2
##
      pic_color
                        0
                                463 463
                                            5
                                               11
                                                       0
                                                                 2
                                                                 2
                        0
                                463 463
##
     pic_outfit
                                            6
                                               10
                                                       0
##
                        0
                                463 463
                                            7
                                               12
                                                       0
                                                                 3
            rank
##
```

```
-- Variable type:numeric ----
##
##
         variable missing complete
                                                                p25
                                                                      p50
                                                                             p75
                                        n
                                           mean
                                                    sd
                                                           p0
##
                          0
                                                 9.8
                                                                           57
                                 463 463 48.37
                                                       29
                                                              42
                                                                    48
               age
##
                          0
                                                               3.17
                                                                     4.33
                                                                           5.5
          bty_avg
                                 463 463
                                           4.42
                                                  1.53
                                                        1.67
                                                                     4
##
      bty_f1lower
                          0
                                 463 463
                                           3.96
                                                  1.87
                                                        1
                                                               2
                                                                            5
##
      bty_f1upper
                                 463 463
                                           5.02
                                                  1.93
                                                               4
                                                                     5
                                                                            7
                          0
                                                        1
                                                                     5
                                                                            6
##
      bty_f2upper
                          0
                                 463 463
                                           5.21
                                                  2.02
                                                        1
                                                               4
##
                                                               2
                                                                     3
                                                                            5
      bty_m1lower
                          0
                                 463 463
                                           3.41
                                                 1.64
                                                        1
                                                                     4
                                                                            5
##
      bty_m1upper
                          0
                                 463 463
                                           4.15 2.11 1
                                                               3
```

```
##
                         0
                                463 463
                                         4.75
                                                1.58
                                                                   5
                                                                         6
      bty m2upper
                                                            15
                                                                  23
                                                                        40
##
                         0
                                463 463 36.62 45.02
                                                     5
     cls_did_eval
                                463 463 74.43 16.76 10.42
                                                                  76.92 87.25
##
    cls_perc_eval
                         0
                                                           62.7
                                                                  29
                                                                        60
##
     cls_students
                         0
                                463 463 55.18 75.07
                                                      8
                                                            19
##
            score
                                463 463
                                         4.17
                                                0.54
                                                      2.3
                                                            3.8
                                                                   4.3
                                                                         4.6
##
      p100
               hist
##
     73
           <U+2585><U+2585><U+2585><U+2587><U+2587><U+2587><U+2587><U+2587>
##
      8.17 <U+2582><U+2585><U+2585><U+2587><U+2583><U+2583><U+2582><U+2581>
##
      8
           <U+2583><U+2587><U+2586><U+2586><U+2585><U+2582><U+2582>
##
      9
           <U+2583><U+2586><U+2587><U+2585><U+2586><U+2586><U+2583><U+2581>
##
     10
           <U+2583><U+2583><U+2586><U+2587><U+2587><U+2582><U+2582><U+2583>
      7
##
           <U+2582><U+2587><U+2585><U+2585><U+2581><U+2583><U+2582><U+2581>
##
      9
           <U+2587><U+2587><U+2587><U+2587><U+2583><U+2582><U+2581>
           <U+2582><U+2583><U+2587><U+2586><U+2585><U+2582><U+2581><U+2581>
##
      9
##
    380
           <U+2587><U+2581><U+2581><U+2581><U+2581><U+2581><U+2581><U+2581><U+2581><U+2581>
##
    100
           <U+2581><U+2581><U+2581><U+2582><U+2585><U+2586><U+2587><U+2586>
    581
##
           <U+2587><U+2581><U+2581><U+2581><U+2581><U+2581><U+2581><U+2581><U+2581>
##
      5
           <U+2581><U+2581><U+2582><U+2583><U+2585><U+2587><U+2586>
```

Umumnya berkas csv menggunakan penanda koma (,) untuk memisahkan antar kolom dan titik (.) sebagai penanda desimal. Namun bagaimana jika Anda memiliki berkas csv yang yang menggunakan titik-koma (;) untuk memisahkan kolom dan koma (,) sebagai penanda desimal? Sebagai contoh, pada direktori data-raw terdapar berkas evals2 yang memiliki kriteria tersebut. Anda dapat menggunakan fungsi read_csv2 untuk mengimpor berkas tersebut sebagaimana ditunjukan pada contoh berikut:

```
evals2 <- read_csv2("../data-raw/evals2.csv")</pre>
## Using ',' as decimal and '.' as grouping mark. Use read_delim() for more control.
## Parsed with column specification:
  cols(
##
##
     .default = col_double(),
##
     rank = col_character(),
##
     ethnicity = col_character(),
##
     gender = col_character(),
##
     language = col_character(),
##
     cls_level = col_character(),
##
     cls_profs = col_character(),
##
     cls_credits = col_character(),
##
     pic_outfit = col_character(),
     pic_color = col_character()
##
## )
## See spec(...) for full column specifications.
identical(evals, evals2) # fungsi untuk cek kesamaan antara dua obyek
```

[1] TRUE

Selain berkas lokal yang tersedia di komputer, Anda juga dapat mengimpor berkas yang tersedia di internet langsung dengan menggunakan pranala (URL). Caranya adalah dengan mengganti lokasi berkas lokal dengan lokasi berkas remote. Data evals tersedia pada pranala "https://www.openintro.org/stat/data/evals.csv".

Dapatkan Anda mengimpor berkas tersebut dan menyimpannya sebagai obyek dengan nama evals3? Gunakkan fungsi identical() untuk membandingkannya dengan evals2!

```
evals3 <- read_csv("https://www.openintro.org/stat/data/evals.csv")</pre>
```

```
## Parsed with column specification:
## cols(
##
     .default = col double(),
##
     rank = col_character(),
     ethnicity = col_character(),
##
##
     gender = col_character(),
     language = col_character(),
##
     cls_level = col_character(),
##
     cls_profs = col_character(),
##
##
     cls_credits = col_character(),
##
     pic_outfit = col_character(),
     pic_color = col_character()
##
## )
## See spec(...) for full column specifications.
identical(evals3, evals2)
```

Tidy data

[1] TRUE

Demi memahami konsep Tidy Data, kita akan menggunakan dataset yang tersedia di paket tidyr. Aktifkanlah paket tidyr tersebut!

```
library(tidyr)
```

```
## Warning: package 'tidyr' was built under R version 3.5.3
```

Dari dataset berikut ini, manakah yang termasuk Tidy Data? Dapatkah Anda menjelaskan alasan mengapa beberapa dataset berikut tidak *tidy*?

table1

```
## # A tibble: 6 x 4
     country
                  year
                        cases population
##
     <chr>>
                 <int>
                        <int>
                                   <int>
## 1 Afghanistan 1999
                          745
                                19987071
## 2 Afghanistan
                  2000
                         2666
                                20595360
## 3 Brazil
                  1999
                        37737 172006362
## 4 Brazil
                  2000 80488 174504898
## 5 China
                  1999 212258 1272915272
## 6 China
                  2000 213766 1280428583
```

table2

```
## # A tibble: 12 x 4

## country year type count

## 
## 1 Afghanistan 1999 cases 745

## 2 Afghanistan 1999 population 19987071

## 3 Afghanistan 2000 cases 2666

## 4 Afghanistan 2000 population 20595360

## 5 Brazil 1999 cases 37737

## 6 Brazil 1999 population 172006362

## 7 Brazil 2000 cases 80488

## 8 Brazil 2000 population 174504898

## 9 China 1999 cases 212258

## 10 China 1999 population 1272915272

## 11 China 2000 cases 213766

## 12 China 2000 population 1280428583
```

table3

table4a

table4b

table5

A tibble: 6 x 4

##		country	century	year	rate
##	*	<chr></chr>	<chr></chr>	<chr>></chr>	<chr></chr>
##	1	Afghanistan	19	99	745/19987071
##	2	Afghanistan	20	00	2666/20595360
##	3	Brazil	19	99	37737/172006362
##	4	Brazil	20	00	80488/174504898
##	5	China	19	99	212258/1272915272
##	6	China	20	00	213766/1280428583