Impor Data dan Konsep Tidy Data

Muhammad Aswan Syahputra 4/9/2019

Impor Data

Anda dapat menggunakan paket readr untuk mengimpor berkas lokal di komputer atau dari pranala (URL). Anda dapat mengaktifkan paket readr dengan cara menjalankan library(nama_paket) seperti contoh berikut: (Petunjuk: Tekan Ctrl + Enter untuk menjalankan baris kode.)

```
library(readr)
```

```
## Warning: package 'readr' was built under R version 3.5.3
```

Paket hanya perlu dipasang satu kali melalui fungsi install.packages("nama_paket") dan harus selalu diaktifkan setiap menggawali kerja menggunakan R agar fungsi-fungsi yang tersedia dalam paket tersebut dapat digunakan. Sebagai contoh, kita akan menggunakan fungsi read_csv() dari paket readr untuk mengimpor data 'evals.csv' dari folder 'data-raw' sebagai berikut:

```
evals <- read_csv("../data-raw/evals.csv")</pre>
```

```
## Parsed with column specification:
## cols(
##
     .default = col double(),
##
     rank = col_character(),
##
     ethnicity = col_character(),
     gender = col_character(),
##
##
     language = col character(),
##
     cls level = col character(),
     cls_profs = col_character(),
##
     cls_credits = col_character(),
##
##
     pic_outfit = col_character(),
     pic_color = col_character()
##
## )
```

See spec(...) for full column specifications.

evals

```
## # A tibble: 463 x 21
##
      score rank ethnicity gender language
                                                age cls_perc_eval cls_did_eval
##
      <dbl> <chr> <chr>
                             <chr>
                                    <chr>>
                                              <dbl>
                                                            <dbl>
                                                                          <dbl>
##
        4.7 tenu~ minority female english
                                                 36
                                                             55.8
                                                                             24
   1
        4.1 tenu~ minority female english
                                                 36
                                                             68.8
                                                                             86
        3.9 tenu~ minority female english
                                                             60.8
##
                                                 36
                                                                             76
##
        4.8 tenu~ minority female english
                                                 36
                                                             62.6
                                                                             77
##
   5
        4.6 tenu~ not mino~ male
                                    english
                                                 59
                                                             85
                                                                             17
        4.3 tenu~ not mino~ male
                                                 59
                                                             87.5
                                                                             35
                                    english
        2.8 tenu~ not mino~ male
                                                 59
                                                             88.6
                                                                             39
##
                                    english
```

```
##
        4.1 tenu~ not mino~ male
                                   english
                                                51
                                                           100
                                                51
## 9
       3.4 tenu~ not mino~ male
                                   english
                                                            56.9
                                                                          111
        4.5 tenu~ not mino~ female english
                                                40
                                                            87.0
                                                                           40
## # ... with 453 more rows, and 13 more variables: cls_students <dbl>,
## #
       cls_level <chr>, cls_profs <chr>, cls_credits <chr>,
## #
       bty_f1lower <dbl>, bty_f1upper <dbl>, bty_f2upper <dbl>,
       bty m1lower <dbl>, bty m1upper <dbl>, bty m2upper <dbl>,
       bty_avg <dbl>, pic_outfit <chr>, pic_color <chr>
## #
```

Anda dapat menggunakan fungsi glimpse dari paket dplyr untuk melihat ringkasan data. tersebut. Isilah '____' dengan jawaban yang tepat untuk melihat ringkasan data evals! Ada berapa variable dan observasi pada data evals tersebut?

library(dplyr)

```
## Warning: package 'dplyr' was built under R version 3.5.3

##
## Attaching package: 'dplyr'

## The following objects are masked from 'package:stats':
##
## filter, lag

## The following objects are masked from 'package:base':
##
## intersect, setdiff, setequal, union
```

glimpse(evals)

```
## Observations: 463
## Variables: 21
## $ score
                                           <dbl> 4.7, 4.1, 3.9, 4.8, 4.6, 4.3, 2.8, 4.1, 3.4, 4.5...
                                           <chr> "tenure track", "tenure track", "tenure track", ...
## $ rank
                                           <chr> "minority", "minority", "minority", "minority", ...
## $ ethnicity
                                           <chr> "female", "female", "female", "female", "male", ...
## $ gender
                                           <chr> "english", "english", "english", "english", "eng...
## $ language
                                           <dbl> 36, 36, 36, 36, 59, 59, 59, 51, 51, 40, 40, 40, ...
## $ age
## $ cls_perc_eval <dbl> 55.81395, 68.80000, 60.80000, 62.60163, 85.00000...
## $ cls_did_eval
                                           <dbl> 24, 86, 76, 77, 17, 35, 39, 55, 111, 40, 24, 24,...
## $ cls_students
                                           <dbl> 43, 125, 125, 123, 20, 40, 44, 55, 195, 46, 27, ...
                                           <chr> "upper", "
## $ cls_level
## $ cls_profs
                                           <chr> "single", "single", "single", "single", "multipl...
## $ cls_credits
                                           <chr> "multi credit", "multi credit", "multi credit", ...
                                           <dbl> 5, 5, 5, 5, 4, 4, 4, 5, 5, 2, 2, 2, 2, 2, 2, 2, ...
## $ bty_f1lower
## $ bty_f1upper
                                           <dbl> 7, 7, 7, 7, 4, 4, 4, 2, 2, 5, 5, 5, 5, 5, 5, 5, ...
## $ bty_f2upper
                                           <dbl> 6, 6, 6, 6, 2, 2, 2, 5, 5, 4, 4, 4, 4, 4, 4, 4, ...
## $ btv m1lower
                                           <dbl> 2, 2, 2, 2, 2, 2, 2, 2, 2, 3, 3, 3, 3, 3, 3, 3, ...
## $ bty_m1upper
                                           <dbl> 4, 4, 4, 4, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, ...
## $ bty_m2upper
                                           <dbl> 6, 6, 6, 6, 3, 3, 3, 3, 2, 2, 2, 2, 2, 2, 2, ...
## $ bty_avg
                                           <dbl> 5.000, 5.000, 5.000, 5.000, 3.000, 3.000, 3.000,...
## $ pic_outfit
                                           <chr> "not formal", "not formal", "not formal", "not f...
                                           <chr> "color", "color", "color", "color", "color", "co...
## $ pic_color
```

Selain itu Anda juga dapat menggunakan fungsi skim() dari paket skimr untuk melihat rangkuman data. Pada *chunck* berikut, tuliskan kode untuk mengaktifkan paket skimr dan menjalankan fungsi skim pada data evals! Perbedaaan apakah yang Anda temukan antara penggunaan fungsi glimpse() dan skim()?

library(skimr)

```
## Warning: package 'skimr' was built under R version 3.5.3
## Attaching package: 'skimr'
## The following object is masked from 'package:stats':
##
##
       filter
skim(evals)
## Skim summary statistics
    n obs: 463
##
##
    n variables: 21
##
##
      Variable type:character
##
       variable missing complete
                                     n min max
                                                empty n_unique
##
    cls_credits
                       0
                               463 463
                                         10
                                             12
                                                     0
                                                               2
                       0
                                                               2
##
      cls_level
                               463 463
                                          5
                                              5
                                                     0
##
      cls_profs
                       0
                               463 463
                                          6
                                              8
                                                     0
                                                               2
                                                               2
##
      ethnicity
                       0
                               463 463
                                          8
                                             12
                                                     0
                                                               2
##
                       0
                                          4
                                              6
         gender
                               463 463
                                                     0
                                                               2
##
       language
                       0
                               463 463
                                          7
                                             11
                                                     0
                       0
                                                               2
##
      pic_color
                               463 463
                                          5
                                             11
                                                     0
                                                               2
##
     pic_outfit
                       0
                               463 463
                                          6
                                             10
                                                     0
                       0
                               463 463
                                                               3
##
           rank
                                          7
                                             12
                                                     0
##
##
   -- Variable type:numeric -----
                                                                            p75
                                                               p25
                                                                      p50
         variable missing complete
##
                                        n
                                           mean
                                                    sd
                                                          p0
##
                          0
                                 463 463 48.37
                                                 9.8
                                                       29
                                                             42
                                                                    48
                                                                          57
               age
##
                                                                     4.33
          bty_avg
                          0
                                 463 463
                                           4.42
                                                 1.53
                                                        1.67
                                                              3.17
                                                                           5.5
##
      bty_f1lower
                          0
                                 463 463
                                           3.96
                                                 1.87
                                                        1
                                                               2
                                                                     4
                                                                            5
                                                               4
                                                                     5
                                                                           7
##
      bty_f1upper
                          0
                                 463 463
                                           5.02
                                                 1.93
                                                        1
                                                                     5
                                                                            6
##
      bty_f2upper
                                 463 463
                                           5.21
                                                 2.02
                                                               4
                          0
                                                        1
                                                               2
                                                                     3
##
      bty_m1lower
                          0
                                 463 463
                                           3.41
                                                 1.64
                                                        1
                                                                            5
##
                                                 2.11
                                                               3
                                                                     4
                                                                            5
      bty_m1upper
                          0
                                 463 463
                                           4.15
                                                        1
##
      bty_m2upper
                          0
                                 463 463
                                           4.75
                                                 1.58
                                                        1
                                                               4
                                                                     5
                                                                            6
##
     cls_did_eval
                          0
                                 463 463 36.62 45.02
                                                              15
                                                                    23
                                                                          40
##
                                 463 463 74.43 16.76 10.42 62.7
                                                                    76.92 87.25
    cls_perc_eval
                          0
##
     cls_students
                          0
                                 463 463 55.18 75.07
                                                        8
                                                              19
                                                                    29
                                                                          60
##
                          0
                                 463 463
                                           4.17
                                                 0.54
                                                        2.3
                                                               3.8
                                                                     4.3
                                                                           4.6
             score
##
      p100
                hist
##
     73
            <U+2585><U+2585><U+2585><U+2587><U+2585><U+2587><U+2587><U+2587>
##
      8.17 <U+2582><U+2585><U+2585><U+2587><U+2583><U+2583><U+2582><U+2581>
##
            <U+2583><U+2587><U+2586><U+2587><U+2586><U+2585><U+2582><U+2582>
##
            <U+2583><U+2586><U+2587><U+2585><U+2586><U+2583><U+2581>
```

```
##
     10
           <U+2583><U+2583><U+2586><U+2587><U+2582><U+2582><U+2583>
##
           <U+2582><U+2587><U+2585><U+2585><U+2581><U+2583><U+2582><U+2581>
      7
##
     9
           <U+2587><U+2587><U+2587><U+2587><U+2583><U+2582><U+2581>
##
      9
           <U+2582><U+2583><U+2587><U+2586><U+2585><U+2582><U+2581><U+2581>
##
   380
           <U+2587><U+2581><U+2581><U+2581><U+2581><U+2581><U+2581><U+2581><U+2581><U+2581>
   100
           <U+2581><U+2581><U+2581><U+2582><U+2585><U+2586><U+2587><U+2586>
##
   581
           <U+2587><U+2581><U+2581><U+2581><U+2581><U+2581><U+2581>
##
      5
           <U+2581><U+2581><U+2582><U+2583><U+2585><U+2587><U+2586>
##
```

Umumnya berkas csv menggunakan penanda koma (,) untuk memisahkan antar kolom dan titik (.) sebagai penanda desimal. Namun bagaimana jika Anda memiliki berkas csv yang yang menggunakan titik-koma (;) untuk memisahkan kolom dan koma (,) sebagai penanda desimal? Sebagai contoh, pada direktori data-raw terdapar berkas evals2 yang memiliki kriteria tersebut. Anda dapat menggunakan fungsi read_csv2 untuk mengimpor berkas tersebut sebagaimana ditunjukan pada contoh berikut:

```
evals2 <- read_csv2("../data-raw/evals2.csv")</pre>
## Using ',' as decimal and '.' as grouping mark. Use read delim() for more control.
## Parsed with column specification:
## cols(
##
     .default = col_double(),
##
     rank = col_character(),
     ethnicity = col_character(),
##
##
     gender = col_character(),
##
     language = col_character(),
##
     cls_level = col_character(),
##
     cls_profs = col_character(),
##
     cls_credits = col_character(),
     pic_outfit = col_character(),
##
##
    pic_color = col_character()
## )
## See spec(...) for full column specifications.
identical(evals, evals2) # fungsi untuk cek kesamaan antara dua obyek
```

[1] TRUE

Selain berkas lokal yang tersedia di komputer, Anda juga dapat mengimpor berkas yang tersedia di internet langsung dengan menggunakan pranala (URL). Caranya adalah dengan mengganti lokasi berkas lokal dengan lokasi berkas remote. Data evals tersedia pada pranala "https://www.openintro.org/stat/data/evals.csv". Dapatkan Anda mengimpor berkas tersebut dan menyimpannya sebagai obyek dengan nama evals3? Gunakkan fungsi identical() untuk membandingkannya dengan evals2!

```
evals3 <- read_csv("https://www.openintro.org/stat/data/evals.csv")</pre>
```

```
## Parsed with column specification:
## cols(
## .default = col_double(),
## rank = col_character(),
```

```
##
     ethnicity = col_character(),
##
     gender = col_character(),
     language = col_character(),
##
     cls_level = col_character(),
##
##
     cls_profs = col_character(),
##
     cls_credits = col_character(),
##
     pic_outfit = col_character(),
     pic_color = col_character()
##
## )
## See spec(...) for full column specifications.
identical(evals3, evals2)
## [1] TRUE
```

Tidy data

Demi memahami konsep Tidy Data, kita akan menggunakan dataset yang tersedia di paket tidyr. Aktifkanlah paket tidyr tersebut!

```
library(tidyr)
```

```
## Warning: package 'tidyr' was built under R version 3.5.3
```

Dari dataset berikut ini, manakah yang termasuk Tidy Data? Dapatkah Anda menjelaskan alasan mengapa beberapa dataset berikut tidak *tidy*?

table1

```
## # A tibble: 6 x 4
##
     country
                       cases population
                year
     <chr>
                 <int>
                       <int>
                                   <int>
## 1 Afghanistan 1999
                         745
                               19987071
## 2 Afghanistan 2000
                        2666
                               20595360
## 3 Brazil
                 1999
                       37737 172006362
## 4 Brazil
                 2000
                       80488 174504898
## 5 China
                 1999 212258 1272915272
## 6 China
                 2000 213766 1280428583
```

table2

```
## # A tibble: 12 x 4
##
      country
                                        count
                  year type
##
      <chr>
                  <int> <chr>
                                        <int>
  1 Afghanistan 1999 cases
                                          745
   2 Afghanistan 1999 population
                                     19987071
## 3 Afghanistan
                  2000 cases
                                         2666
## 4 Afghanistan 2000 population
                                     20595360
## 5 Brazil
                  1999 cases
                                       37737
```

```
## 6 Brazil 1999 population 172006362
## 7 Brazil 2000 cases 80488
## 8 Brazil 2000 population 174504898
## 9 China 1999 cases 212258
## 10 China 1999 population 1272915272
## 11 China 2000 cases 213766
## 12 China 2000 population 1280428583
```

table3

```
## # A tibble: 6 x 3

## country year rate

## * <chr> <int> <chr> <int> <chr>
## 1 Afghanistan 1999 745/19987071

## 2 Afghanistan 2000 2666/20595360

## 3 Brazil 1999 37737/172006362

## 4 Brazil 2000 80488/174504898

## 5 China 1999 212258/1272915272

## 6 China 2000 213766/1280428583
```

table4a

```
## # A tibble: 3 x 3
## country 1999 2000
## * <chr> ## 1 Afghanistan 745 2666
## 2 Brazil 37737 80488
## 3 China 212258 213766
```

table4b

table5