Transformasi Data

Muhammad Aswan Syahputra 4/9/2019

Contents

Non-tidy menjadi Tidy dataset	1
Data Wrangling	-

Non-tidy menjadi Tidy dataset

Anda akan menggunakan fungsi spread dari paket tidyr untuk mengubah memperbaiki dataset 'table2' (juga dari paket tidyr). Aktifkanlah paket tidyr, lihat dataset 'table2'. Apakah yang membuat dataset tersebut non-tidy data? Bukalah dokumentasi fungsi spread dengan menjalankan ?nama_fungsi atau help(nama_fungsi)!

```
library(tidyr)
```

Warning: package 'tidyr' was built under R version 3.5.3

table2

```
## # A tibble: 12 x 4
##
      country
                   year type
                                         count
##
      <chr>
                  <int> <chr>
                                         <int>
   1 Afghanistan 1999 cases
                                           745
   2 Afghanistan
                   1999 population
##
                                      19987071
   3 Afghanistan
##
                   2000 cases
                                          2666
##
   4 Afghanistan
                   2000 population
                                      20595360
##
   5 Brazil
                   1999 cases
                                         37737
##
   6 Brazil
                   1999 population
                                    172006362
##
   7 Brazil
                   2000 cases
                                        80488
                   2000 population 174504898
##
   8 Brazil
  9 China
                   1999 cases
##
                                        212258
## 10 China
                   1999 population 1272915272
## 11 China
                   2000 cases
                                        213766
## 12 China
                   2000 population 1280428583
```

Dataset 'table2' dapat diperbaiki dengan menjalankan kode berikut:

```
table2_tidy <- spread(table2, key = "type", value = "count")</pre>
```

Selanjutnya Anda juga akan memperbaiki dataset 'table4a'. Cetaklah dataset tersebut dan dapatkah Anda menyebutkan alasan mengapa dataset tersebut tidak *tidy* dan *tame*?

table4a # cetak dataset table4a

Dataset 'table4a' dapat diperbaiki dengan menggunakan fungsi gather dari tidyr. Anda dapat mempelajari fungsi tersebut dengan menjalankan ?gather.

```
gather(table4a, key = "year", value = "case", 2:3)
## # A tibble: 6 x 3
##
     country
                 year
                         case
##
     <chr>
                 <chr>>
                        <int>
## 1 Afghanistan 1999
                          745
## 2 Brazil
                 1999
                        37737
## 3 China
                 1999 212258
## 4 Afghanistan 2000
                         2666
## 5 Brazil
                 2000
                        80488
## 6 China
                 2000 213766
table4a_tidy <- table4a %>%
 gather(key = "year", value = "cases", 2:3) # menggunakan tidyverse syntax, pipe %>%
```

Silakan lakukan hal serupa pada dataset 'table4b' namun dengan menggunakan "population" sebagai isian argumen value. Tuliskan juga dengan menggunakan *tidyverse syntax* dan simpan obyek tersebut dengan nama 'table4b_tidy'!

```
table4b
```

2 Brazil

4 Afghanistan 2000

5 Brazil 2000

3 China

6 China

1999

172006362

20595360

174504898

1999 1272915272

2000 1280428583

```
## # A tibble: 3 x 3
    country
                     1999
                                2000
## * <chr>
                                 <int>
                      <int>
## 1 Afghanistan
                   19987071
                              20595360
## 2 Brazil
                  172006362 174504898
## 3 China
                 1272915272 1280428583
table4b_tidy <- table4b %>%
  gather(key = "year", value = "cases", 2:3) # mengqunakan tidyverse syntax, pipe %>%
table4b_tidy
## # A tibble: 6 x 3
##
     country
                 year
                            cases
##
     <chr>
                 <chr>>
                            <int>
## 1 Afghanistan 1999
                         19987071
```

Dataset 'table4a_tidy' dan 'table4b_tidy' tersebut dapat digabungkan menjadi satu dataset. Hal tersebut dapat dilakukan dengan menggunakan fungsi left_join dari paket dplyr seperti contoh berikut:

```
library(dplyr) # mengaktifkan paket dplyr

## Warning: package 'dplyr' was built under R version 3.5.3

##

## Attaching package: 'dplyr'

## The following objects are masked from 'package:stats':

##

## filter, lag

## The following objects are masked from 'package:base':

##

## intersect, setdiff, setequal, union

mydata <- left_join(table4a_tidy, table4b_tidy)

## Joining, by = c("country", "year", "cases")</pre>
```

Data Wrangling

Dataset mydata tersebut merupakan subset dataset Tubercolusis yang diolah dari data 'who' dan 'population' (dari paket tidyr). Lihatlah ringkasan kedua tersebut dengan menggunakan glimpse!

```
glimpse(who)
```

```
## Observations: 7,240
## Variables: 60
    <chr> "Afghanistan", "Afghanistan", "Afghanistan", "Afg...
## $ country
## $ iso2
    <chr> "AF", "AF", "AF", "AF", "AF", "AF", "AF", "AF", "AF", "...
    <chr> "AFG", "AFG", "AFG", "AFG", "AFG", "AFG", "AFG", ...
## $ iso3
    <int> 1980, 1981, 1982, 1983, 1984, 1985, 1986, 1987, 1...
## $ year
## $ new sp m65
    ## $ new_sp_f65
```

```
## $ new sn m65
## $ new_sn_f65
## $ new ep m65
## $ new_ep_f65
## $ newrel_m65
## $ newrel f65
```

glimpse(population)

Sekarang kita akan membuat versi utuh dari dataset 'mydata' dengan menggunakan data seluruh negara pada dataset 'who' sebagai berikut:

```
# Menjalankan fungsi satu per satu
tb1 <- gather(who, key = "key", value = "case", new_sp_m014:newrel_f65)
tb2 <- select(tb1, country, year, case)</pre>
tb3 <- group_by(tb2, country, year)</pre>
tb4 <- summarise(tb3, cases = sum(case, na.rm = TRUE))
tb5 <- ungroup(tb4)</pre>
tb6 <- left_join(tb5, population)</pre>
## Joining, by = c("country", "year")
tb7 <- filter(tb6, !is.na(population))</pre>
tb8 <- mutate(tb7, proportion = 100*cases/population)
# Syntax menggunakan pipe %>%
tb all <-
  who %>%
  gather(key = "key", value = "case", new_sp_m014:newrel_f65) %>%
  select(country, year, case) %>%
  group_by(country, year) %>%
  summarise(cases = sum(case, na.rm = TRUE)) %>%
  ungroup() %>%
  left_join(population) %>%
  filter(!is.na(population)) %>%
  mutate(proportion = 100*cases/population)
```

Joining, by = c("country", "year")

Dapatkah Anda membuat ringkasan apa saja hal apa saja yang dilakukan pada proses data wrangling diatas? (Petunjuk: ?nama_fungsi)

- 1. ...
- 2. ...
- 3. ...
- 4. ...
- 5. ... 6. ...
- 7. ...
- 8. ...

Cek apakah dataset 'tb8' sama dengan dataset 'tb_all'! Menurut Anda, cara penulisan syntax manakah yang lebih mudah digunakan dan dipahami?

```
tb8
```

```
## # A tibble: 4,037 x 5
     country
                 year cases population proportion
##
##
     <chr>
                 <int> <int>
                                 <int>
                                            <dbl>
                                         0
## 1 Afghanistan 1995
                          0
                              17586073
## 2 Afghanistan 1996
                          0 18415307
## 3 Afghanistan 1997
                             19021226
                                         0.000673
                       128
```

```
## 4 Afghanistan 1998 1778
                             19496836
                                       0.00912
## 5 Afghanistan 1999
                       745
                                       0.00373
                             19987071
## 6 Afghanistan 2000
                      2666
                                       0.0129
                             20595360
## 7 Afghanistan 2001 4639
                             21347782
                                       0.0217
## 8 Afghanistan 2002
                      6509
                             22202806
                                       0.0293
## 9 Afghanistan 2003 6528
                             23116142
                                       0.0282
## 10 Afghanistan 2004 8245
                             24018682
                                       0.0343
## # ... with 4,027 more rows
```

tb_all

```
## # A tibble: 4,037 \times 5
##
     country
                 year cases population proportion
##
     <chr>
                 <int> <int>
                                 <int>
                                           <dbl>
  1 Afghanistan 1995
                        0
                              17586073
                                        0
## 2 Afghanistan 1996
                        0
                              18415307
                                        0
## 3 Afghanistan 1997
                              19021226
                                        0.000673
                       128
## 4 Afghanistan 1998 1778
                                        0.00912
                              19496836
## 5 Afghanistan 1999
                       745
                              19987071
                                        0.00373
## 6 Afghanistan 2000 2666
                                        0.0129
                              20595360
## 7 Afghanistan 2001 4639
                              21347782
                                        0.0217
## 8 Afghanistan 2002 6509
                              22202806
                                        0.0293
## 9 Afghanistan 2003
                       6528
                              23116142
                                        0.0282
## 10 Afghanistan 2004
                       8245
                              24018682
                                        0.0343
## # ... with 4,027 more rows
```